



고려대학교
KOREA UNIVERSITY



AI Security

- Lecture 05. Unsupervised Learning Techniques

Artificial Intelligence Research (AIR) LAB

<https://air.korea.ac.kr/>

School of Cybersecurity

Korea University

Sangkyun Lee (이상근)

2025. Spring Semester

비지도 학습 기법

오늘날 대부분의 머신러닝 응용은 지도학습을 기반으로 하지만, 사용 가능한 데이터의 대부분은 레이블이 없음. 입력 특성 X 는 있지만 레이블 y 는 없는 상태.

얀 르쿤은 "지능이 케이크라면, 비지도 학습은 케이크 자체, 지도 학습은 케이크 위의 아이싱, 강화 학습은 케이크 위의 체리"라고 말함. 즉, 비지도 학습에는 우리가 아직 겨우 맛보기 시작한 엄청난 잠재력이 있음.


이 장에서는 다음과 같은 비지도 학습 작업을 살펴볼 것임:

-  **클러스터링**
유사한 인스턴스를 클러스터로 그룹화하는 것이 목표. 데이터 분석, 고객 세분화, 추천 시스템 등에 유용함.
-  **이상치 탐지**
"정상" 데이터가 어떤 모습인지 학습한 다음 비정상적인 인스턴스를 탐지하는 것이 목표. 사기 탐지, 제조 과정에서 결함 제품 식별 등에 유용함.
-  **밀도 추정**
데이터셋을 생성한 랜덤 프로세스의 확률 밀도 함수(PDF)를 추정하는 작업. 이상치 탐지에 주로 사용됨.

클러스터링 알고리즘: k-means와 DBSCAN

클러스터링은 유사한 인스턴스를 식별하고 이를 클러스터 또는 유사한 인스턴스 그룹에 할당하는 작업임.

분류와 마찬가지로 각 인스턴스는 그룹에 할당되지만, 분류와 달리 클러스터링은 비지도 작업임.



왼쪽은 레이블이 있는 붓꽃 데이터셋으로, 각 인스턴스의 종(클래스)이 다른 마커로 표시됨. 로지스틱 회귀, SVM, 랜덤 포레스트 분류기와 같은 분류 알고리즘에 적합함.

오른쪽은 레이블이 없는 동일한 데이터셋으로, 분류 알고리즘을 더 이상 사용할 수 없음. 이때 클러스터링 알고리즘이 필요함.

분류(왼쪽)와 클러스터링(오른쪽) 비교

클러스터링의 응용



고객 세분화

구매 및 웹사이트 활동을 기반으로 고객을 클러스터링할 수 있음. 고객이 누구이고 무엇이 필요한지 이해하는 데 유용하여 각 세그먼트에 맞게 제품과 마케팅 캠페인을 조정할 수 있음.



데이터 분석

새 데이터셋을 분석할 때 클러스터링 알고리즘을 실행한 다음 각 클러스터를 별도로 분석하는 것이 유용함.



차원 축소

데이터셋이 클러스터링되면 각 인스턴스의 클러스터 친화도를 측정할 수 있음. 각 인스턴스의 특성 벡터를 클러스터 친화도 벡터로 대체할 수 있음.



특성 엔지니어링

클러스터 친화도는 추가 특성으로 유용할 수 있음. 예를 들어, 캘리포니아 주택 데이터셋에 지리적 클러스터 친화도 특성을 추가하여 성능을 향상시킬 수 있음.



이상치 탐지

모든 클러스터에 대한 친화도가 낮은 인스턴스는 이상치일 가능성이 높음. 예를 들어, 웹사이트 사용자를 행동에 따라 클러스터링한 경우 비정상적인 행동을 보이는 사용자를 감지할 수 있음.




준지도 학습

레이블이 몇 개만 있는 경우 클러스터링을 수행하고 레이블을 동일한 클러스터의 모든 인스턴스로 전파할 수 있음. 이 기술은 지도 학습 알고리즘에 사용할 수 있는 레이블 수를 크게 늘릴 수 있음.

k-means 알고리즘

k-means 알고리즘은 각 클러스터의 중심을 찾고 각 인스턴스를 가장 가까운 클러스터(blob)에 할당:




k-means 결정 경계(보로노이 테셀레이션)

- 대부분의 인스턴스는 명확하게 적절한 클러스터에 할당되었지만, 일부 인스턴스는 특히 왼쪽 상단 클러스터와 중앙 클러스터 사이의 경계 근처에서 잘못 레이블링되었을 가능성이 있음.
- k-means는 인스턴스를 클러스터에 할당할 때 중심까지 거리만 고려하기 때문에 클러스터의 직경이 매우 다른 경우에는 잘 작동하지 않음.

k-means 알고리즘의 작동 방식


1. 무작위로 센트로이드를 배치하고(예: 데이터셋에서 무작위로 k개의 인스턴스를 선택하고 해당 위치를 중심으로 사용) 시작.
2. 레이블링: 각 인스턴스를 가장 가까운 센트로이드로 지정
3. 업데이트: 소속된 인스턴스의 중심점으로 센트로이드를 업데이트.
4. 센트로이드가 움직임을 멈출 때까지 2-4 반복.



k-means 알고리즘

알고리즘은 유한한 수의 단계(일반적으로 매우 적음)에서 수렴하도록 보장됨.


- 알고리즘이 수렴하도록 보장되지만 올바른 솔루션으로 수렴하지 않을 수 있음(즉, 지역 최적점에 수렴할 수 있음).
- 중심 초기화에 따라 결과가 달라짐.



미니배치 k-means

2010년 David Sculley의 논문: 각 반복에서 전체 데이터셋을 사용하는 대신, 미니배치를 사용하여 각 반복에서 중심을 약간씩 이동시킬 수 있음. 이는 알고리즘 속도를 높이고(일반적으로 3~4배) 메모리에 맞지 않는 대규모 데이터셋을 클러스터링할 수 있게 함.

미니배치 k-means 알고리즘은 일반 k-means 알고리즘보다 훨씬 빠르지만, 관성은 일반적으로 약간 더 나쁨.




미니배치 k-means는 k-means보다 관성이 높지만(왼쪽) 훨씬 빠름(오른쪽), 특히 k가 증가할수록 더욱 그러함

관성(inertia): k-means 알고리즘의 성능 지표로, 각 샘플이 자신이 속한 클러스터의 중심으로부터 얼마나 떨어져 있는지를 나타내는 거리의 제곱합임. 관성 값이 낮을수록 클러스터가 더 밀집되어 있고 더 잘 분리되어 있다는 것을 의미하며, 클러스터링 품질이 더 좋다고 볼 수 있음.

왼쪽 그래프는 다양한 클러스터 수 k를 사용하여 이전 5개 블록 데이터셋에서 훈련된 미니배치 k-means와 일반 k-means 모델의 관성을 비교함. 두 곡선 간의 차이는 작지만 눈에 띈다.

오른쪽 그래프에서는 미니배치 k-means가 이 데이터셋에서 일반 k-means보다 약 3.5배 빠른 것을 볼 수 있음.

최적의 클러스터 수 찾기: 관성




지금까지 데이터를 보면 5개가 올바른 클러스터 수임이 분명했기 때문에 클러스터 수 k 를 5로 설정함. 그러나 일반적으로 k 를 어떻게 설정해야 하는지 알기가 쉽지 않으며, 잘못된 값으로 설정하면 결과가 상당히 나쁠 수 있음.

관성이 가장 낮은 모델을 선택하면 된다고 생각할 수 있음. 불행히도 그렇게 간단하지 않음. $k=3$ 일 때 관성은 약 653.2로 $k=5$ 일 때(211.6)보다 훨씬 높음. 그러나 $k=8$ 일 때 관성은 119.1에 불과함.

클러스터 수에 대한 잘못된 선택: k 가 너무 작으면 별도의 클러스터가 병합되고(왼쪽), k 가 너무 크면 일부 클러스터가 여러 조각으로 분할됨(오른쪽)

관성은 k 를 선택할 때 좋은 성능 지표가 아님. 클러스터가 많을수록 각 인스턴스는 가장 가까운 중심에 더 가까워지므로 관성이 낮아짐.



k 의 함수로 관성을 그래프로 그려보면, 곡선에는 종종 엘보(elbow)라고 하는 변곡점이 포함됨.

k 를 4까지 증가시키면 관성이 매우 빠르게 감소하지만, k 를 계속 증가시키면 훨씬 더 천천히 감소함. 이 곡선은 대략 팔 모양이며 $k=4$ 에서 엘보가 있음.

따라서 더 잘 알지 못한다면 4가 좋은 선택이라고 생각할 수 있음: 더 낮은 값은 극적일 것이고, 더 높은 값은 크게 도움이 되지 않을 것임.

최적의 클러스터 수 찾기: 실루엣 점수

k-means에서 최적의 k 값을 선택하기 위한 또 다른 방법: 실루엣 점수(silhouette score).

실루엣 점수란?

각 샘플에 대해 같은 클러스터 내 다른 샘플과의 평균 거리(a)와 가장 가까운 다른 클러스터 샘플과의 평균 거리(b)를 사용하여 계산합니다.

$$\text{실루엣 계수} = (b - a) / \max(a, b)$$


실루엣 점수는 모든 샘플의 실루엣 계수 평균값입니다.

점수 해석

실루엣 점수는 -1에서 1 사이의 값을 가집니다:

- 1에 가까울수록: 클러스터가 잘 분리됨
- 0에 가까울수록: 클러스터가 겹침
- 음수: 샘플이 잘못된 클러스터에 할당됨

실루엣 시각화를 통해 각 클러스터의 품질을 직관적으로 확인 가능.




k-means의 한계

Suboptimal 솔루션을 피하기 위해 알고리즘을 여러 번 실행해야 하며, 클러스터 수를 지정해야 함.

또한 k-means는 클러스터의 크기가 다양하거나, 밀도가 다르거나, 비구형 형태일 때 잘 작동하지 않음.

예: 아래 그림은 k-means가 다양한 밀도 및 방향을 가진 세 개의 타원형 클러스터를 포함하는 데이터셋을 클러스터링



그림에서 왼쪽이 더 나은 편이지만, 여전히 중간 클러스터의 25%를 잘라내어 오른쪽 클러스터에 할당함. 오른쪽 솔루션은 관성이 낮음에도 불구하고 부적합.

이러한 유형의 타원형 클러스터에서는 가우시안 mixture 모델이 훌륭하게 작동함.

준지도 학습을 위한 클러스터링 사용

클러스터링의 또 다른 사용 사례는 레이블이 없는 인스턴스가 많고 레이블이 있는 인스턴스가 매우 적은 준지도 학습임.

0부터 9까지의 숫자를 나타내는 1,797개의 그레이스케일 8×8 이미지를 포함하는 간단한 MNIST와 유사한 데이터셋인 숫자 데이터셋 사용:

50개의 인스턴스에 대해서만 레이블이 있다고 가정:

- 로지스틱 회귀 모델의 정확도는 74.8%에 불과함. 전체 훈련 세트에서 모델을 훈련시키면 약 90.7%의 정확도에 도달함.

대표 이미지 추가 레이블링: 더 나은 결과를 얻기 위해 훈련 세트를 50개의 클러스터로 클러스터링함. 그런 다음 각 클러스터에 대해 중심에 가장 가까운 이미지를 찾음. 이러한 이미지를 대표 이미지라고 부름.

각 이미지를 보고 수동으로 레이블을 지정함. 이제 50개의 레이블이 있는 인스턴스로 구성된 데이터셋이 있지만, 무작위 인스턴스 대신 각각이 클러스터의 대표 이미지임. 성능이 더 나아졌는지 확인해보면 정확도가 74.8%에서 84.9%로 향상됨.

레이블 전파: 더 나아가 레이블을 동일한 클러스터의 다른 모든 인스턴스로 전파하면 어떻게 될까? 이 방법을 사용하면 정확도가 89.4%로 다시 크게 향상됨.




그림 9-13. 50개의 대표 숫자 이미지(클러스터당 하나)

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

DBSCAN 알고리즘은 클러스터를 높은 밀도의 연속 영역으로 정의함. 작동 방식은 다음과 같음:

ϵ -이웃 계산

각 인스턴스에 대해 알고리즘은 작은 거리 ϵ (엡실론) 내에 위치한 인스턴스 수를 계산함.

클러스터 형성


핵심 인스턴스의 이웃에 있는 모든 인스턴스는 동일한 클러스터에 속함. 이 이웃에는 다른 핵심 인스턴스가 포함될 수 있으므로 인접한 핵심 인스턴스의 긴 시퀀스가 단일 클러스터를 형성함.

핵심 인스턴스 식별

인스턴스의 ϵ -이웃에 최소 `min_samples` 인스턴스(자신 포함)가 있는 경우 핵심 인스턴스로 간주됨. 즉, 핵심 인스턴스는 밀도가 높은 영역에 위치한 인스턴스임.

이상치 식별

자신이 핵심 인스턴스가 아니고 이웃에 핵심 인스턴스가 없는 인스턴스는 이상치로 간주됨.



DBSCAN은 모든 클러스터가 낮은 밀도 영역을 사이에 두고 분리되어 있으면 잘 작동함.

하지만, ϵ 값에 따라 왼쪽: 많은 이상치와 7개의 서로 다른 클러스터를 식별함. 오른쪽: ϵ 를 0.2로 증가시키면 각 인스턴스의 이웃을 넓히면 완벽해 보이는 클러스터링을 얻을 수 있음.

다른 클러스터링 알고리즘



응집 (Agglomerative) 클러스터링

응집 클러스터링은 가장 가까운 클러스터 쌍을 반복적으로 연결함(개별 인스턴스로 시작). 클러스터의 계층 구조가 아래에서 위로 구축됨.

계층적 클러스터링의 한 종류임



친화도 전파

이 알고리즘에서는 모든 인스턴스가 다른 인스턴스(또는 자신)를 대표로 선출할 때까지 인스턴스가 반복적으로 메시지를 교환함. 이렇게 선출된 인스턴스를 대표(exemplars)라고 함. 각 대표와 그것을 선출한 모든 인스턴스가 하나의 클러스터를 형성함.



BIRCH

Balanced Iterative Reducing and Clustering using Hierarchies (BIRCH) 알고리즘은 매우 큰 데이터셋을 위해 설계됨. 특성 수가 너무 많지 않은 한(<20) 배치 k-means보다 빠르고 유사한 결과를 얻을 수 있음. 훈련 중에 트리 구조를 구축, 모든 인스턴스를 트리에 저장하지 않고도 새 인스턴스를 클러스터에 빠르게 할당하는 데 필요한 정보만 포함함.



Mean-shift

k-means와 유사. 시작을 무작위 클러스터 중심에 인스턴스를 배치하는 대신, 각 인스턴스를 중심으로 원을 배치하는 것으로 시작. 그런 다음 각 원에 대해 그 안에 위치한 모든 인스턴스의 평균을 계산하고, 원을 이동시켜 평균을 중심으로 함. 모든 원이 움직임을 멈출 때까지 이 중심→평균 이동을 반복.




스펙트럼 클러스터링

이 알고리즘은 인스턴스 간의 유사성 행렬을 가져와 저차원 임베딩을 생성한 다음(즉, 행렬의 차원을 줄임) 이 저차원 공간에서 다른 클러스터링 알고리즘을 사용(Scikit-Learn의 구현은 k-means를 사용함). 스펙트럼 클러스터링은 복잡한 클러스터 구조를 포착할 수 있으며 그래프를 자르는 데도 사용할 수 있음(예: 소셜 네트워크에서 친구 클러스터 식별).

가우시안 분포


평균(μ)과 표준편차(σ)로 완전히 정의되는 연속 확률 분포. 종 모양의 곡선으로 시각화되며, 평균을 중심으로 대칭적임.

단변량 가우시안 분포



- 데이터의 68%는 $\mu \pm 1\sigma$ 내에 위치
- 데이터의 95%는 $\mu \pm 2\sigma$ 내에 위치
- 데이터의 99.7%는 $\mu \pm 3\sigma$ 내에 위치

다변량 가우시안 분포



다변량 가우시안 분포는 여러 변수에 대한 결합 확률 분포로, 평균 벡터(μ)와 공분산 행렬(Σ)로 정의.

$$p(x) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right)$$

여기서 d 는 차원의 수, $|\Sigma|$ 는 공분산 행렬의 행렬식, Σ^{-1} 은 공분산 행렬의 역행렬을 나타냅니다. 고차원에서 가우시안 분포는 '차원의 저주'와 관련된 여러 특성을 보여주며, 데이터가 분포의 중심에서 멀리 떨어질 확률이 급격히 증가합니다.

가우시안 혼합 (Gaussian Mixture) 모델

가우시안 혼합 모델(GMM)은 각 인스턴스가 여러 가우시안 분포의 혼합에서 생성되었다고 가정하는 확률적 모델임.


각 인스턴스는 다음과 같은 확률적 프로세스를 통해 생성되었다고 가정함:

클러스터 선택

각 인스턴스에 대해 k 개의 클러스터 중에서 무작위로 클러스터가 선택됨. j 번째 클러스터를 선택할 확률은 클러스터의 가중치 $\phi(j)$ 임. i 번째 인스턴스에 대해 선택된 클러스터의 인덱스는 $z(i)$ 로 표시됨.

위치 샘플링

i 번째 인스턴스가 j 번째 클러스터에 할당된 경우(즉, $z(i) = j$), 이 인스턴스의 위치 $x(i)$ 는 평균 $\mu(j)$ 와 공분산 행렬 $\Sigma(j)$ 를 가진 가우시안 분포에서 무작위로 샘플링됨. 이는 $x(i) \sim \mathcal{N}(\mu(j), \Sigma(j))$ 로 표시됨.



가우시안 혼합 모델의 학습: EM 알고리즘

가우시안 혼합 모델은 기대값 최대화(Expectation Maximization, EM) 알고리즘으로 학습할 수 있음.

EM 알고리즘은 k-means 알고리즘과 유사: 클러스터 매개변수를 무작위로 초기화한 다음 수렴할 때까지 두 단계를 반복함.

- E-Step: 인스턴스를 클러스터에 할당
- M-Step: 클러스터를 업데이트

k-means와 달리 EM은 하드 할당이 아닌 소프트 클러스터 할당을 사용함. 각 인스턴스에 대해 기대값 단계에서 알고리즘은 현재 클러스터 매개변수를 기반으로 각 클러스터에 속할 확률을 추정함. 그런 다음 최대화 단계에서 각 클러스터는 데이터셋의 모든 인스턴스를 사용하여 업데이트되며, 각 인스턴스는 해당 클러스터에 속할 것으로 추정된 확률에 따라 가중치가 부여됨.

이상치 탐지를 위한 가우시안 혼합 사용

이상치 탐지에 가우시안 혼합 모델을 사용하는 것은 매우 간단함:

즉, 낮은 밀도 영역에 위치한 인스턴스는 이상치로 간주. 단, 밀도 임계값을 정의해야 함.

- 예를 들어, 결함 제품을 탐지하려는 제조 회사에서 결함 제품의 비율은 일반적으로 잘 알려져 있음. 2%라고 가정해보면, 밀도 임계값을 인스턴스의 2%가 해당 임계값 밀도 이하의 영역에 위치하도록 하는 값으로 설정함.
- 임계값에 따라 서로 다른 FN, FP이 발생하며, 정밀도/재현율 트레이드 오프 역시 발생함

이상치 탐지 vs. 새로운 것 탐지(novelty detection): 후자는 알고리즘이 이상치에 의해 오염되지 않은 "깨끗한" 데이터 셋에서 훈련된다고 가정한다는 점에서 이상치 탐지와 다름.

가우시안 혼합: 클러스터 수 선택

k-means에서는 관성이나 실루엣 점수를 사용하여 적절한 클러스터 수를 선택할 수 있음.


그러나 가우시안 혼합에서는 클러스터가 구형이 아니거나 크기가 다른 경우 이러한 메트릭이 신뢰할 수 없기 때문에 사용할 수 없음.

대신 베이지안 정보 기준(BIC) 또는 아카이케 정보 기준(AIC)과 같은 이론적 정보 기준을 최소화하는 모델을 찾을 수 있음.

$$BIC = -\log(m)p - 2\log(\hat{L})$$

$$AIC = 2p - 2\log(\hat{L})$$

- m: 인스턴스 수
- p: 모델이 학습한 매개변수 수
- hat L: 모델의 최대 우도 함수값




베이지안 가우시안 혼합 모델

최적 클러스터 수를 수동 검색 대신 BayesianGaussianMixture 클래스 사용 가능.

클러스터 수 `n_components`를 최적의 클러스터 수보다 크다고 믿을 만한 이유가 있는 값으로 설정하면(이는 문제에 대한 최소한의 지식을 가정함) 알고리즘이 불필요한 클러스터를 자동으로 제거함.

가우시안 혼합 모델에 대한 참고 사항: 타원형 모양의 클러스터에서는 잘 작동하지만 매우 다른 모양의 클러스터에서는 그렇게 잘 작동하지 않음. 예를 들어, 베이지안 가우시안 혼합 모델을 사용하여 달 데이터셋을 클러스터링하면 다음의 결과를 얻음:



베이지안 가우시안 혼합 모델 학습 알고리즘이 필사적으로 타원체를 찾으려고 해서 두 개 대신 여덟 개의 서로 다른 클러스터를 찾음. 밀도 추정은 그리 나쁘지 않으므로 이 모델은 이상치 탐지에 사용될 수 있지만, 두 개의 달을 식별하는 데는 실패함.

이상치/Novelty 탐지를 위한 다른 알고리즘

ooo Fast-MCD

EllipticEnvelope 클래스. 특히 데이터셋을 정리하기 위한 이상치 탐지에 유용. 정상 인스턴스가 단일 가우시안 분포에서 생성되었다고 가정. 또한 데이터셋이 이 가우시안 분포에서 생성되지 않은 이상치로 오염되었다고 가정함.

○ One-class SVM

이 알고리즘은 novelty 탐지에 더 적합함. 커널화된 SVM 분류기는 먼저 모든 인스턴스를 고차원 공간에 (암시적으로) 매핑한 다음 이 고차원 공간 내에서 선형 SVM 분류기를 사용하여 두 클래스를 분리함. 인스턴스 클래스가 하나뿐이므로 one-class SVM 알고리즘은 대신 고차원 공간에서 인스턴스를 원점과 분리하려고 시도함.

📍 Local outlier factor (LOF)

주어진 인스턴스 주변의 밀도를 이웃 주변의 밀도와 비교함. 이상치는 종종 k -최근접 이웃보다 더 고립되어 있음.



Isolation forest

특히 고차원 데이터셋에서 이상치 탐지를 위한 효율적인 알고리즘.

각 결정 트리가 무작위로 성장하는 랜덤 포레스트를 구축 → 각 노드에서 특성을 무작위로 선택한 다음 데이터셋을 두 부분으로 분할하기 위한 무작위 임계값을 선택함. 이런 식으로 데이터셋이 점차 조각으로 잘려 모든 인스턴스가 다른 인스턴스와 격리될 때까지 진행됨.

이상치 탐지에 효과적인 이유: 이상치는 본질적으로 데이터 공간에서 더 고립되어 있기 때문에 격리하는 데 필요한 분할 횟수가 적음. 즉, 정상 데이터 포인트는 더 많은 분할이 필요한 반면, 이상치는 쉽게 격리됨. 각 데이터 포인트를 격리하는 데 필요한 평균 경로 길이를 측정하여 이상치 점수를 계산.



PCA 및 기타 차원 축소 기법

정상 인스턴스의 재구성 오류와 이상치의 재구성 오류를 비교하면 후자가 일반적으로 훨씬 더 높음. 이는 간단하고 종종 매우 효율적인 이상치 탐지 접근 방식임.

연습 문제

1. 클러스터링을 어떻게 정의할 수 있는가? 몇 가지 클러스터링 알고리즘을 말할 수 있는가?
2. 클러스터링 알고리즘의 주요 응용 분야는 무엇인가?
3. k-means를 사용할 때 올바른 클러스터 수 선택에 사용할 수 있는 실루엣 점수를 설명하라.
4. 레이블 전파란 무엇인가? 왜 구현하며, 어떻게 구현하는가?
5. DBSCAN의 아이디어는?
6. 클러스터링을 이상치 탐지에 어떻게 사용할 수 있는가?
7. 가우시안 혼합이란 무엇인가? 어떤 작업에 사용할 수 있는가?
8. 가우시안 혼합의 클러스터 수를 결정하는 방법은? 클러스터 수 결정 없이 사용할 수 있는 방법은? 주의점은?

Thank You